

# PROJET DE FIN D'ÉTUDES

Système de Détection d'Anomalies pour  
Moteurs Industriels basé sur  
l'Intelligence Artificielle Embarquée  
Application du TinyML pour la Maintenance  
Prédictive

Présenté par :  
Ahmed Abdellahi ABDAT

Encadré par :  
Dr. Khalil JOULI

Formation :  
Master Électronique,  
Énergie Électrique et  
Automatique

Année universitaire :  
2024-2025

## Jury de Soutenance

Président : Pr. [À définir]  
Rapporteur : Dr. Khalil JOULI  
Examineur : Dr. [À définir]

Date de soutenance : \_\_\_\_\_



---

# REMERCIEMENTS

*À mes parents, pour leur amour et leur soutien inconditionnel*

*À mes frères et sœurs, pour leurs encouragements constants*

Nos remerciements vont tout d'abord à **Dieu Tout-Puissant** pour la volonté, la santé et la patience qu'Il nous a accordées durant toutes ces années.

Nous exprimons notre profonde gratitude à nos **parents**, ainsi qu'à nos **frères et sœurs**, qui nous ont soutenus par leurs encouragements tout au long de nos études.

Nous adressons également nos plus sincères remerciements à **Dr. Khalil Jouili**, pour son encadrement, ses conseils méthodologiques et sa disponibilité tout au long de ce projet.

Enfin, nous remercions toute personne, de près ou de loin, qui a contribué à rendre ce travail réalisable et présentable.



---

# RÉSUMÉ

Ce projet présente le développement d'un système de détection d'anomalies pour moteurs asynchrones triphasés basé sur l'intelligence artificielle embarquée (TinyML). L'approche proposée explore le potentiel du TinyML pour rendre la maintenance prédictive plus accessible aux PME industrielles, utilisant l'apprentissage non-supervisé (K-means) nécessitant uniquement des données de fonctionnement normal. Le prototype développé, d'un coût inférieur à 50€, vise une détection en temps réel avec une latence d'inférence inférieure à 10ms et une autonomie totale sans dépendance cloud. Les tests réalisés sur un moteur asynchrone triphasé (0,37 kW) au laboratoire universitaire FSB montrent une précision supérieure à 90% dans la détection d'anomalies vibratoires simulées (résultats détaillés au Chapitre 3). Ce travail de recherche explore la faisabilité technique d'une approche TinyML pour la maintenance prédictive, une validation en conditions industrielles réelles étant nécessaire pour confirmer son applicabilité pratique.

**Mots-clés :** TinyML, Maintenance prédictive, Microcontrôleur embarqué, Détection d'anomalies, K-means, Analyse vibratoire, Industry 4.0, Edge Computing



---

# ABSTRACT

This project presents the development of an anomaly detection system for three-phase asynchronous motors based on embedded artificial intelligence (TinyML). The proposed approach explores the potential of TinyML to make predictive maintenance more accessible to industrial SMEs, employing unsupervised learning (K-means) requiring only normal operating data. The developed prototype, costing less than €50, targets real-time detection with inference latency below 10ms and complete autonomy without cloud dependency. Tests conducted at the FSB university laboratory on a three-phase asynchronous motor (0.37 kW) show accuracy exceeding 90% in detecting simulated vibration anomalies (detailed results in Chapter 3). This research work explores the technical feasibility of a TinyML approach for predictive maintenance, with validation under real industrial conditions necessary to confirm its practical applicability.

**Keywords :** TinyML, Predictive maintenance, Embedded microcontroller, Anomaly detection, K-means, Vibration analysis, Industry 4.0, Edge Computing



---

# TABLE DES MATIÈRES

Remerciements	i
Résumé	ii
Abstract	iii
LISTE DES TABLEAUX	vi
LISTE DES TABLEAUX	vi
LISTE DES FIGURES	vii
LISTE DES FIGURES	vii
Liste des symboles	viii
Introduction Générale	1
1 État de l’Art	2
1.1 Introduction . . . . .	3
1.2 Stratégies de maintenance . . . . .	3
1.2.1 Typologie de la maintenance industrielle . . . . .	3
1.2.2 Enjeux économiques des temps d’arrêt . . . . .	4
1.2.3 Défis pour les PME et positionnement du projet . . . . .	5
1.3 Analyse vibratoire . . . . .	5
1.3.1 Cadre normatif et évaluation . . . . .	5
1.3.2 Acquisition de données et capteurs . . . . .	6

1.3.3	Traitement du signal et extraction de caractéristiques . . . . .	6
1.3.4	Caractéristiques vibratoires courantes . . . . .	7
1.4	Détection d'anomalies par Apprentissage Automatique . . . . .	8
1.4.1	Approches non supervisées et semi-supervisées . . . . .	8
1.4.2	Approches supervisées et <i>Deep Learning</i> (DL) . . . . .	8
1.5	TinyML Industriel . . . . .	9
1.5.1	Définition et Contraintes Techniques . . . . .	10
1.5.2	Chaîne d'outils et Optimisation . . . . .	10
1.5.3	Cas d'application en détection d'anomalies vibratoires . . . . .	11
1.6	Synthèse critique et positionnement . . . . .	12
<b>Bibliographie</b>		<b>14</b>



---

# LISTE DES TABLEAUX

1.1	Comparaison des algorithmes ML pour la détection d'anomalies vibratoires	9
-----	--	---



---

# LISTE DES FIGURES

1.1	Types de maintenance industrielle . . . . .	4
-----	---	---





---

# LISTE DES SYMBOLES



---

# Introduction Générale

Dans le contexte de l'Industrie 4.0, la maintenance prédictive s'affirme comme un levier essentiel pour améliorer la disponibilité des équipements et réduire les arrêts non planifiés. Elle prolonge la maintenance conditionnelle en exploitant l'analyse des données de fonctionnement — notamment les vibrations — et des méthodes d'intelligence artificielle pour détecter précocement les comportements anormaux.

Toutefois, le déploiement de solutions complètes reste difficile pour de nombreuses entreprises en raison des coûts, de la complexité d'intégration et de la dépendance à des infrastructures réseau.

Dans ce cadre, le paradigme TinyML — exécuter des modèles d'IA directement sur des microcontrôleurs — offre une alternative intéressante pour analyser au plus près de la machine, avec une faible latence, une meilleure confidentialité et des coûts contenus.

Ce mémoire présente une étude sur le développement d'un système de détection d'anomalies pour moteurs industriels basé sur TinyML, explorant le potentiel de cette technologie pour rendre la maintenance prédictive plus accessible aux PME industrielles. Notre étude explore l'utilisation d'algorithmes d'apprentissage non-supervisé sur microcontrôleur embarqué. La validation expérimentale, réalisée en laboratoire universitaire, permet d'évaluer la faisabilité technique de cette approche.

**Note méthodologique :** Ce travail se concentre sur la *faisabilité technique* d'une implémentation TinyML pour la détection d'anomalies vibratoires. Les estimations économiques citées visent à contextualiser l'enjeu stratégique, mais ne constituent pas l'objet principal de validation de ce PFE. Une évaluation économique complète (calcul de ROI, analyse coût-bénéfice sur équipements réels) nécessiterait un déploiement industriel à long terme dépassant le cadre d'un projet de fin d'études.

Le présent document est structuré comme suit :

Le **Chapitre 1** présente l'état de l'art, établissant les bases théoriques nécessaires : l'évolution de la maintenance industrielle, les concepts fondamentaux de l'analyse vibratoire et du TinyML, ainsi qu'une revue critique de la littérature récente pour identifier les lacunes et positionner notre contribution.

Les chapitres suivants, en cours de rédaction, détailleront la conception du système, sa réalisation pratique et les résultats expérimentaux obtenus.

---

## CHAPITRE

# 1

# État de l'Art de la Détection d'Anomalies Vibratoires par TinyML

---

## 1.1 Introduction

Dans le contexte de l'Industrie 4.0, la maintenance prédictive (PdM) est devenue un impératif stratégique visant à garantir la fiabilité et la continuité de la production [1, 2]. La PdM, en s'appuyant sur des algorithmes avancés, permet d'anticiper les défaillances des équipements rotatifs, dont l'état est principalement évalué par la surveillance vibratoire [3]. Traditionnellement, l'analyse des données d'intelligence artificielle (IA) s'effectuait sur des serveurs distants ou dans le *cloud*, imposant des contraintes de latence, de bande passante et de coût [4].

Le paradigme du TinyML (*Tiny Machine Learning*) apporte une solution disruptive en déplaçant l'inférence des modèles d'apprentissage automatique (ML) directement sur le dispositif embarqué (*Edge*) [5]. Cette approche permet la détection d'anomalies en temps réel au plus près de la source de données, même dans des environnements contraints. Le présent chapitre propose un état de l'art structuré autour de quatre axes majeurs : l'évolution des stratégies de maintenance, les fondements de l'analyse vibratoire, les méthodologies de détection d'anomalies par apprentissage automatique, et l'application du paradigme TinyML dans le secteur industriel.

## 1.2 Stratégies de maintenance

L'évolution des pratiques de maintenance industrielle est marquée par une quête constante d'optimisation des coûts et d'amélioration de la fiabilité des systèmes, progressant d'une approche réactive à une stratégie proactive et anticipative [3]. La normalisation, notamment par la norme européenne EN 13306 :2017, fournit un cadre terminologique essentiel pour distinguer ces stratégies [6].

### 1.2.1 Typologie de la maintenance industrielle

La norme EN 13306 [6] et les travaux de revue [3] définissent principalement trois grandes catégories d'actions de maintenance :

**Maintenance Corrective (RM – Reactive Maintenance) :** Il s'agit de la stratégie la plus élémentaire, exécutée uniquement après qu'une défaillance se soit produite et que l'équipement soit dans un état défectueux [6, 3]. Bien que simple à mettre en œuvre pour les actifs non critiques, elle entraîne inévitablement des temps d'arrêt imprévus, des coûts de réparation élevés, estimés jusqu'à trois fois supérieurs à ceux d'une maintenance planifiée, et des risques de dommages collatéraux [3].

**Maintenance Préventive (PM – Preventive Maintenance) :** Cette stratégie vise à éviter la panne en planifiant des interventions à des intervalles prédéterminés (basés sur le temps ou l'usage) ou selon une condition prédéfinie [6, 3]. La maintenance préventive systématique réduit l'aléa mais présente l'inconvénient d'un risque de sur-entretien coûteux, où des composants sont remplacés avant que leur durée de vie utile ne soit atteinte [3].

**Maintenance Prédictive (PdM – Predictive Maintenance)** : La PdM représente la forme la plus évoluée de maintenance conditionnelle (CBM) [2, 7, 8]. Elle s'appuie sur la surveillance de l'état réel de l'équipement (*condition monitoring*) pour prédire le moment futur de la défaillance. La PdM permet d'optimiser l'intervalle de maintenance (*adaptive intervals*) en fonction de l'état de santé du système, assurant une intervention juste à temps.

*Note* : Selon EN 13306, la PdM est techniquement un sous-ensemble de la CBM. Cette étude adopte la classification tripartite courante pour clarté pédagogique.

La **Maintenance Conditionnelle (CBM)**, définie par l'ISO 17359 [9], fonde ses décisions sur l'observation des indicateurs de l'état de l'équipement. La CBM est considérée comme un précurseur de la PdM. La PdM étend la CBM par l'intégration d'outils d'analyse avancée (ML/DL) pour effectuer le **Pronostic** (prédiction de l'évolution de la dégradation et de la Durée de Vie Résiduelle, RUL) en plus du **Diagnostic** (identification de la cause de la panne). Le cadre d'ingénierie qui intègre ces deux tâches est appelé *Prognostics and Health Management* (PHM) [7, 2].



**Figure 1.1** – *Types de maintenance industrielle*

### 1.2.2 Enjeux économiques des temps d'arrêt

Les temps d'arrêt imprévus (*unplanned downtime*) constituent un enjeu économique majeur pour l'industrie manufacturière. Selon une analyse sectorielle réalisée par Siemens en 2024, basée sur une enquête auprès de 181 professionnels de la maintenance entre 2019 et 2023, les coûts horaires d'immobilisation varient considérablement selon le secteur [10]<sup>1</sup> :

- Biens de consommation courante (FMCG) : 36 000 \$/heure
- Industrie automobile : jusqu'à 2,3 millions \$/heure dans les grandes usines

1. Ces données proviennent d'un rapport industriel (Siemens Senseye, 2024) et n'ont pas fait l'objet d'une validation académique indépendante par des revues évaluées par les pairs. Elles sont utilisées ici pour contextualiser l'enjeu stratégique de la maintenance prédictive.

- Petites et moyennes entreprises : environ 150 000 \$/heure

À l'échelle macroéconomique, les pertes annuelles attribuées aux temps d'arrêt non planifiés pour les 500 plus grandes entreprises mondiales sont estimées à 1,4 trillion de dollars [10]. Le potentiel d'économie associé à l'adoption de la Maintenance Prédictive (PdM) est régulièrement chiffré dans les rapports industriels à une réduction des coûts de maintenance de l'ordre de 40 % [10]. Ces projections, si elles se confirment à grande échelle, représenteraient des économies significatives pour les entreprises industrielles.

### 1.2.3 Défis pour les PME et positionnement du projet

Malgré le potentiel économique de la PdM, les solutions traditionnelles d'IA et d'IoT restent complexes et coûteuses à déployer, notamment pour les PME [10]. Ces dernières font face à des barrières significatives pour l'adoption de la maintenance prédictive [11] :

- Coût prohibitif des solutions commerciales (>5 000 €)
- Absence d'expertise IA/IoT interne
- ROI incertain pour équipements auxiliaires

Le paradigme TinyML, en permettant l'implémentation de modèles ML directement sur des microcontrôleurs à faible coût, pourrait offrir une alternative plus accessible pour la détection d'anomalies vibratoires. Cette approche vise à démocratiser l'accès à la maintenance prédictive pour les entreprises disposant de ressources limitées.

## 1.3 Analyse vibratoire

L'analyse vibratoire est la modalité de surveillance la plus courante et la plus performante pour le *Condition Monitoring* des machines tournantes, car la vibration est la modalité de référence standardisée pour l'évaluation de l'état de ces équipements (ISO 20816/17359) [12, 13]. Les défauts mécaniques tels que le désalignement, le balourd, les roulements endommagés ou les défauts d'engrenage génèrent des signatures distinctes dans les signaux vibratoires [14].

### 1.3.1 Cadre normatif et évaluation

L'évaluation des vibrations est encadrée par les normes internationales de l'Organisation Internationale de Normalisation (ISO), notamment la série ISO 20816.

La **Norme ISO 20816-1 :2016** [12] établit les lignes directrices générales pour la mesure et l'évaluation des vibrations mécaniques des machines, applicable aux mesures effectuées sur les parties tournantes (arbres) et non tournantes (paliers) en conditions de fonctionnement stable. Elle stipule que l'évaluation se fait typiquement en considérant l'amplitude de la vibration large bande observée. Elle précise également les quantités de mesure (déplacement, vitesse, accélération) et la plage de réponse en fréquence requise, qui est d'au moins 10 Hz à 1 000 Hz pour l'évaluation de la vitesse efficace (r.m.s.).

La **Norme ISO 20816-3 :2022** [15] est un document sectoriel qui spécifie les exigences pour l'évaluation des vibrations des machines industrielles accouplées d'une puissance nominale supérieure à 15 kW et fonctionnant entre 120 tr/min et 30 000 tr/min. Elle fournit des critères d'évaluation pour les mesures effectuées *in-situ* sur des paliers ou des supports de palier.

Par ailleurs, la **Norme ISO 17359 :2018** [9] fournit les lignes directrices pour l'établissement d'un programme de surveillance d'état (CBM), incluant la sélection des variables à mesurer et la détermination des critères d'alarme.

### 1.3.2 Acquisition de données et capteurs

L'acquisition des données vibratoires est généralement assurée par des accéléromètres [13]. Historiquement, des capteurs piézoélectriques industriels ont été utilisés, mais la tendance pour les dispositifs IoT et TinyML est à l'intégration d'accéléromètres basés sur la technologie **MEMS** (*Micro-Electro-Mechanical Systems*). Les capteurs MEMS sont privilégiés pour leur faible coût, leur petite taille et leur faible consommation d'énergie, ce qui les rend idéaux pour les systèmes embarqués contraints [13, 16].

### 1.3.3 Traitement du signal et extraction de caractéristiques

Le signal vibratoire brut capturé doit subir un traitement pour en extraire des caractéristiques pertinentes pour le diagnostic. Ce processus suit typiquement une chaîne en plusieurs étapes :

1. **Pré-traitement** : Il inclut le nettoyage des données brutes pour réduire le bruit et les artefacts [17].
2. **Traitement du Signal** : C'est la conversion du signal du domaine temporel au domaine fréquentiel ou temps-fréquence.
3. **Extraction de Caractéristiques** : Calcul d'indicateurs (statistiques, fréquentiels) qui servent d'entrées aux modèles ML/DL.

**Analyse Temporelle** : L'analyse du domaine temporel examine directement la forme d'onde enregistrée pour en extraire des descripteurs statistiques. Le niveau d'amplitude est un bon indicateur de la condition de la machine et de la gravité du défaut. Les caractéristiques couramment utilisées incluent :

- **La Moyenne Quadratique (RMS – Root Mean Square)** : Mesure robuste de l'amplitude de la vibration qui est moins sensible aux variations extrêmes et plus indicative de l'énergie totale du signal.
- **Le Kurtosis (Aplatissement)** : Indicateur statistique de la distribution des pics. Un Kurtosis élevé peut signaler des défauts précoces dans les roulements.

**Analyse Fréquentielle (FFT)** : La Transformation de Fourier Rapide (FFT), introduite par Cooley et Tukey [18], est la technique fondamentale pour convertir le signal temporel en spectre de fréquences. L'analyse fréquentielle permet d'identifier la source des vibrations, car chaque défaut se manifeste à des fréquences caractéristiques spécifiques.

**Théorème de Nyquist et échantillonnage :** Le théorème de Nyquist-Shannon impose une fréquence d'échantillonnage  $f_s \geq 2f_{max}$  pour capturer fidèlement les composantes fréquentielles jusqu'à  $f_{max}$  sans aliasing. La norme ISO 20816-1 spécifie une analyse typiquement jusqu'à 1 kHz pour les machines tournantes [12]. Le choix de  $f_s$  dépend de la vitesse de rotation de la machine et du rang harmonique maximal à surveiller.

**Fenêtrage et fuites spectrales :** L'application directe de la FFT sur des signaux tronqués génère des fuites spectrales. Les fonctions de fenêtrage atténuent ce phénomène :

- **Fenêtre de Hanning :** Réduit les fuites de 31 dB, privilégiée pour l'analyse vibratoire générale
- **Fenêtre de Hamming :** Réduit les fuites de 43 dB, optimale pour distinguer des fréquences proches
- **Fenêtre rectangulaire :** Maximise la résolution fréquentielle mais génère des lobes secondaires importants

**Compromis résolution-latence :** La résolution fréquentielle est donnée par  $\Delta f = f_s/N$  où  $N$  est le nombre de points FFT. La complexité computationnelle de la FFT est  $O(N \log N)$ . Le choix de  $N$  résulte d'un compromis entre la résolution spectrale souhaitée, la latence de calcul acceptable, et les capacités du microcontrôleur. Des valeurs courantes pour les applications embarquées sont  $N \in \{256, 512, 1024, 2048\}$  points.

### 1.3.4 Caractéristiques vibratoires courantes

L'efficacité de la détection d'anomalies dépend de l'extraction de caractéristiques pertinentes. La littérature identifie deux catégories principales [3, 14] :

**Domaine temporel :** Les indicateurs statistiques caractérisent l'amplitude et la distribution du signal vibratoire :

- **RMS (Root Mean Square) :**  $\sqrt{\frac{1}{N} \sum_{i=1}^N x_i^2}$  – Indicateur d'usure générale et d'énergie totale
- **Valeur crête et facteur de crête :**  $\max(|x_i|)$  et  $\frac{\text{Crête}}{\text{RMS}}$  – Sensibles aux chocs et défauts localisés
- **Kurtosis :**  $\frac{\sum (x_i - \bar{x})^4}{N\sigma^4}$  – Détection précoce de défauts de roulements
- **Asymétrie (Skewness) :**  $\frac{\sum (x_i - \bar{x})^3}{N\sigma^3}$  – Indicateur de désalignement

**Domaine fréquentiel :** L'analyse spectrale permet d'identifier la nature du défaut par ses fréquences caractéristiques :

- **Pics harmoniques :** Amplitude à  $1 \times F_r$  (balourd),  $2 \times F_r$  (désalignement), où  $F_r$  est la fréquence de rotation
- **Énergie spectrale par bandes :** Basses fréquences (défauts mécaniques), hautes fréquences (défauts de roulements)
- **Enveloppe spectrale :** Démodulation d'amplitude pour détecter les défauts de roulements



## 1.4 Détection d'anomalies par Apprentissage Automatique

L'apprentissage automatique (ML) est au cœur de la PdM pour l'identification et la classification autonomes des schémas de comportement anormaux [2, 19]. Le choix de la méthode dépend crucialement de la disponibilité de données étiquetées de défaillance, souvent rares en environnement industriel.

### 1.4.1 Approches non supervisées et semi-supervisées

Les méthodes non supervisées sont essentielles pour la détection d'anomalies (AD) dans les scénarios industriels où la majorité des données représentent un fonctionnement normal (état sain) [16]. Ces algorithmes modélisent le comportement normal et signalent tout écart significatif.

**K-means** [20] : Algorithme de clustering proposé par MacQueen, qui partitionne les données en  $k$  groupes en minimisant la variance intra-cluster. Dans le contexte de la maintenance, il modélise les données d'état sain et détecte les anomalies par analyse des distances aux centres de clusters.

L'algorithme itère selon le processus de Lloyd : (1) assignation de chaque point au centre le plus proche, (2) recalcul des centres comme barycentres des points assignés, (3) convergence lorsque les déplacements des centres deviennent négligeables. L'initialisation K-means++ [21], qui sélectionne les centres initiaux avec une probabilité proportionnelle au carré de la distance, offre une garantie d'approximation  $O(\log k)$  et améliore la convergence.

K-means présente des limitations : hypothèse de clusters sphériques, sensibilité à l'initialisation, et nécessité de spécifier  $k$  a priori. La sélection de  $k$  utilise couramment la méthode du coude analysant la variance intra-cluster  $J = \sum_{i=1}^n \min_j \|x_i - \mu_j\|^2$ . Avec une complexité de  $O(nkid)$  où  $n$ =échantillons,  $k$ =clusters,  $i$ =itérations,  $d$ =dimensions, et une empreinte mémoire typique de 20-100 KB selon la configuration, K-means est adapté aux microcontrôleurs contraints.

**Isolation Forest (IF)** : Cet algorithme, particulièrement efficace pour l'AD, isole les anomalies en utilisant des partitions aléatoires. Il est performant et nécessite une complexité moyenne ( $O(n \log n)$ ), le rendant adapté à l'embarqué. Antonini et al. (2023) l'ont utilisé sur microcontrôleur, réalisant une détection d'anomalie en moins de 16 ms avec 84 KB de RAM [22].

**Autoencodeurs (AE)** : Les autoencodeurs sont des réseaux neuronaux non supervisés entraînés à reconstruire les données d'entrée. Ils excellent à modéliser la *normalité*. Une erreur de reconstruction élevée indique une anomalie [3]. Les AE sont utilisés pour la détection d'anomalies dans la maintenance prédictive, notamment en environnement *Edge*.

### 1.4.2 Approches supervisées et *Deep Learning* (DL)

Les méthodes supervisées sont utilisées lorsque des jeux de données de défaillance étiquetées sont disponibles, ce qui permet des tâches de classification et de diagnostic plus précises.

**Machines à Vecteurs de Support (SVM) :** Les SVM sont couramment employés pour la classification des défauts vibratoires [23, 3]. Elles offrent une précision élevée mais leur complexité est généralement quadratique ( $O(n^2)$ ), ce qui peut être gourmand en mémoire pour l'implémentation embarquée.

**Forêts Aléatoires (RF) :** Les RF sont également utilisés pour le diagnostic. Leur performance est jugée bonne dans les benchmarks [17].

L'avènement du *Deep Learning* (DL) a permis d'améliorer la précision en exploitant directement les signaux bruts ou les représentations temps-fréquence sans nécessiter une extraction manuelle de caractéristiques sophistiquée.

**Réseaux Neuronaux Convolutifs (CNN) :** Les CNN, notamment les variantes 1D (CNN-1D) adaptées aux séries temporelles vibratoires, sont très efficaces pour extraire des caractéristiques locales [17, 24]. Langer et al. (2025) ont démontré, dans leur étude, une latence de 84,5 ms pour un CNN optimisé sur microcontrôleur [24].

**Mémoires à Long Terme et Court Terme (LSTM) :** Les réseaux récurrents (RNN) et leurs variantes comme les LSTM ou les GRU (Gated Recurrent Units) sont idéaux pour capturer les dépendances temporelles des données de dégradation [3, 17]. Cependant, ils exigent une utilisation de mémoire élevée, limitant leur déploiement sur les microcontrôleurs ultra-contraints [25].

La comparaison objective des algorithmes met en évidence un compromis crucial : les méthodes DL offrent la meilleure précision mais la plus haute complexité et les besoins en mémoire les plus importants, tandis que les méthodes non supervisées comme K-means ou Isolation Forest offrent un équilibre optimal pour le déploiement sur microcontrôleurs.

**Table 1.1** – *Comparaison des algorithmes ML pour la détection d'anomalies vibratoires*

Algorithme	Complexité	Mémoire (KB)	Précision	Faisabilité Embarquée	Source Mémoire
K-means [20]	$O(nkid)$	20-30 <sup>a</sup>	Élevée	Oui	[20, 21]
Isolation Forest	$O(n \log n)$	84 <sup>b</sup>	Élevée	Oui (<16 ms)	[22]
SVM	$O(n^2)$	200-300 <sup>a</sup>	Très élevée	Limité	[23]
CNN	$O(n \cdot m \cdot k)$	150-250	Très élevée	Avec quant.	[24, 16]
LSTM	$O(n \cdot h^2)$	300-500 <sup>a</sup>	Très élevée	Limité	[3]
Autoencodeurs	$O(n \cdot l \cdot h)$	100-200 <sup>a</sup>	Élevée	Limité	[3, 16]

<sup>a</sup>Estimation qualitative pour paradigme TinyML (< 256 KB SRAM typique)

<sup>b</sup>Valeur mesurée rapportée dans [22]

## 1.5 TinyML Industriel

Le TinyML est l'extension de l'intelligence artificielle jusqu'aux dispositifs d'extrémité (*extreme edge*), permettant l'exécution de modèles ML directement sur des microcontrôleurs

(MCU) à ultra-faible consommation [5, 4]. Ce changement de paradigme est fondamental pour la PdM, car il supprime les dépendances à la connectivité réseau et réduit drastiquement la latence.

### 1.5.1 Définition et Contraintes Techniques

Le TinyML se déploie généralement sur des MCU 32-bit caractérisés par des ressources matérielles extrêmement limitées. Les contraintes typiques sont sévères :

- **Mémoire vive (SRAM)** : Typiquement inférieure à 256 KB.
- **Mémoire flash (Stockage)** : Habituellement limitée (quelques MB).
- **Consommation énergétique** : Faible, souvent de l'ordre du milli-watt.

Ces contraintes imposent l'utilisation de modèles ML extrêmement légers. L'objectif principal est de permettre une inférence en temps réel avec une latence minimale. Il est important de distinguer deux métriques :

- **Latence d'inférence** : Le temps de calcul du modèle ML uniquement, typiquement visé à moins de 10 ms pour les applications critiques.
- **Latence système totale** : Incluant acquisition des données, pré-traitement, inférence et génération d'alerte, généralement inférieure à 100 ms, ce qui reste compatible avec les exigences industrielles de surveillance en temps réel.

### 1.5.2 Chaîne d'outils et Optimisation

Pour que les modèles ML puissent s'exécuter dans un environnement aussi contraint, des outils et des techniques d'optimisation sont indispensables.

**TensorFlow Lite Micro (TFLite Micro)** : Ce cadre logiciel est un moteur d'inférence conçu spécifiquement pour les microcontrôleurs. Il est essentiel pour convertir et optimiser les modèles entraînés sur PC avant leur déploiement sur l'appareil *Edge* [5].

**Edge Impulse** : Plateforme de développement end-to-end qui facilite l'acquisition de données, le traitement des signaux et la création de modèles optimisés pour les applications TinyML. Elle offre plusieurs fonctionnalités adaptées aux microcontrôleurs :

- **Support multi-plateforme** : SDK optimisés pour divers MCU (ESP32, STM32, Arduino) avec accélération matérielle DSP
- **Algorithmes d'apprentissage intégrés** : Bibliothèques de clustering (K-means), classification (Random Forest, SVM), et réseaux neuronaux
- **Pipeline DSP optimisé** : Implémentation CMSIS-DSP de la FFT et autres transformées temps-fréquence
- **Quantification automatique** : Conversion int8/int16 des modèles pour réduire l'empreinte mémoire avec perte minimale de précision

Arciniegas et al. (2025) ont démontré l'efficacité d'Edge Impulse pour la détection vibratoire, atteignant 96.5% de précision avec seulement 45 KB de RAM utilisée [16].

L'optimisation des modèles repose principalement sur des techniques de compression :

- **Quantification** : Réduction de la précision numérique des poids du réseau (par exemple, de 32 bits en virgule flottante à 8 bits entiers). Cela réduit la taille du modèle et accélère l'inférence [16, 24].
- **Élagage (*Pruning*)** : Suppression des connexions et des neurones jugés non essentiels, ce qui réduit la complexité du modèle sans compromettre significativement la précision [5].

### 1.5.3 Cas d'application en détection d'anomalies vibratoires

Les travaux récents démontrent la faisabilité et l'efficacité du TinyML dans la PdM industrielle :

**Antonini et al. (2023)** [22] : Ont développé et validé un système de détection d'anomalies basé sur l'algorithme **Isolation Forest (IF)**, implémenté en *MicroPython* sur un microcontrôleur **ESP32\_WROVER\_IE** (4 MB SPIRAM, 4 MB Flash). Ce système a démontré une robustesse en environnements industriels extrêmes (températures de -40°C à +85°C), avec une latence d'inférence inférieure à 16 ms et une consommation mémoire de **84 KB**. Ces résultats illustrent le potentiel du TinyML pour des applications industrielles contraintes.

**Arciniegas et al. (2025)** [16] : Ont présenté un dispositif TinyML pour la détection de défauts de roulements de moteurs. Leur système, utilisant une analyse spectrale et un réseau neuronal quantifié (*deep learning*), a atteint une précision de **96,5 %** en laboratoire. La latence totale (de l'acquisition de données à l'alerte) était de **300 ms**.

**Langer et al. (2025)** [24] : Ont exploré le TinyML pour la surveillance de machines-outils CNC (fraiseuses), en ciblant la détection rapide des défauts de processus. Ils ont souligné la nécessité d'une co-optimisation poussée du pré-traitement (FFT, spectrogramme) et du modèle ML pour respecter le temps réel. Leur approche basée sur un CNN optimisé a permis une inférence totale de l'ordre de **84,5 ms** dans cette configuration spécifique.

**Gupta et al. (2025)** [25] : Ont implémenté un cadre TinyML pour l'analyse vibratoire et la détection de défauts en temps réel sur équipements industriels, en utilisant la combinaison spécifique de capteurs MEMS et microcontrôleurs. Le modèle, un CNN-1D optimisé, a démontré une précision supérieure à 92 %.

Le TinyML permet théoriquement le déport d'une capacité analytique sophistiquée (y compris *Deep Learning* ou algorithmes d'ensemble) directement sur des dispositifs peu coûteux et autonomes, visant une détection d'anomalies à faible latence potentiellement compatible avec les exigences industrielles en temps réel.

Il est important de reconnaître que la majorité des travaux académiques sur le TinyML pour la maintenance, y compris le nôtre, s'appuient sur des validations en laboratoire avec des défauts contrôlés. Cette approche méthodologique, bien que nécessaire pour établir la faisabilité technique, constitue une première étape vers le déploiement industriel. Les défis de la maintenance à long terme et l'adaptation aux conditions industrielles variables restent des axes de recherche ouverts pour l'ensemble de la communauté scientifique. De plus, le compromis fondamental entre latence et précision reste sous-exploré : une latence réduite (<10 ms) implique souvent des simplifications algorithmiques (réduction du nombre de caractéristiques, quantification agressive) qui peuvent affecter la sensibilité de détection, particulièrement pour les anomalies subtiles ou progressives caractéristiques de l'usure normale des équipements industriels.

## 1.6 Synthèse critique et positionnement

L'analyse de l'état de l'art confirme que la Maintenance Prédicative (PdM) est un impératif économique pour l'industrie, essentiel pour contrecarrer les coûts prohibitifs des arrêts non planifiés (variant de 36 000 \$ à 2,3 millions de dollars par heure selon le secteur [10]). La surveillance vibratoire, encadrée par les normes ISO 20816, est la méthode de prédilection, avec une complexité d'analyse gérable grâce à l'extraction de caractéristiques fréquentielles (FFT).

Le paradigme TinyML offre une opportunité prometteuse pour explorer des approches d'IA plus accessibles pour les systèmes de surveillance contraints. Les études de cas récentes (Antonini 2023, Arciniegas 2025, Langer 2025) ont démontré la faisabilité technique de la détection d'anomalies en temps réel (<100 ms) en utilisant des microcontrôleurs et des modèles optimisés [22, 16, 24].

Cependant, plusieurs lacunes et considérations critiques persistent dans la littérature :

1. **Accessibilité PME** : La documentation des implémentations "clés en main" pour les techniciens de maintenance des PME, dépourvus d'expertise en IA, reste limitée [11].
2. **Transition Lab-Terrain** : Le passage de la validation académique au déploiement industriel reste un défi majeur. Les méthodologies pour adapter les modèles développés en laboratoire aux conditions opérationnelles réelles nécessitent davantage de recherche collaborative industrie-université.
3. **Standardisation des Métriques** : Il existe un manque de *benchmarks* TinyML standardisés spécifiquement pour la maintenance prédictive vibratoire. Les métriques de validation doivent inclure non seulement la précision globale, mais aussi la précision, le rappel, et le score F1, particulièrement important pour évaluer la détection des anomalies rares. MLPerf Tiny, bien qu'existant, se concentre sur d'autres applications [26].
4. **Considérations de Sécurité** : Un aspect critique sous-exploré est la gestion des faux négatifs. Un système de maintenance prédictive doit intégrer des mécanismes de fail-safe pour éviter les défaillances catastrophiques en cas d'anomalie non détectée. Une approche à seuils multiples avec alertes progressives est recommandée.
5. **Comparaison Baseline** : Les études actuelles manquent souvent de comparaison avec les méthodes traditionnelles (inspection manuelle, maintenance préventive calendaire) en termes de coût/efficacité, rendant difficile l'évaluation du gain réel pour les PME.
6. **Détails d'Optimisation** : Les détails précis de l'optimisation des flux de données et des modèles (quantification, gestion mémoire dynamique) pour les architectures MCU ultra-contraintes ne sont pas toujours divulgués dans les publications académiques, complexifiant la reproduction des performances.

**Positionnement critique** : L'analyse de l'état de l'art révèle un décalage entre le potentiel économique théorique de la PdM (économies projetées de 40 % des coûts de maintenance selon les rapports industriels [10]) et les défis pratiques du déploiement TinyML sur microcontrôleurs contraints. Les contraintes matérielles (mémoire limitée, puissance de calcul réduite) imposent des compromis algorithmiques qui peuvent affecter la précision

de détection. De plus, la majorité des validations expérimentales publiées s'appuient sur des conditions de laboratoire avec des défauts contrôlés [22, 16, 24], laissant ouverte la question de la robustesse en environnement industriel réel avec variabilité des charges, conditions environnementales, et modes de dégradation progressifs.

Ces lacunes identifiées orientent vers le développement de solutions adaptées aux contraintes industrielles réelles, dont la conception sera détaillée dans le chapitre suivant.

# Bibliographie

- [1] I. Hector and R. Panjanathan, “Predictive maintenance in Industry 4.0 : A survey of planning models and machine learning techniques,” *PeerJ Computer Science*, vol. 10, p. e2016, 2024.
- [2] M. Achouch, M. Dimitrova, K. Ziane, S. Sattarpanah Karganroudi, R. Dhouib, H. Ibrahim, and M. Adda, “On predictive maintenance in Industry 4.0 : Overview, models, and challenges,” *Applied Sciences*, vol. 12, no. 16, p. 8081, 2022.
- [3] Y. Ran, X. Zhou, P. Lin, Y. Wen, and R. Deng, “A survey of predictive maintenance : Systems, purposes and approaches,” *arXiv preprint arXiv :1912.07383*, 2019, updated March 2024, comprehensive PdM survey.
- [4] E. Njor, M. A. Hasanpour, J. Madsen, and X. Fafoutis, “A holistic review of the TinyML stack for predictive maintenance,” *IEEE Access*, vol. 12, pp. 184 861–184 882, 2024, comprehensive TinyML+PdM pipeline review.
- [5] V. Tsoukas, A. Gkogkidis, E. Boumpa, and A. Kakarountas, “A review on the emerging technology of TinyML,” *ACM Computing Surveys*, vol. 56, no. 10, pp. 259 :1–259 :37, 2024.
- [6] *EN 13306 :2017 — Maintenance — Maintenance terminology*, European Committee for Standardization Std., 2017.
- [7] J. Lee, F. Wu, W. Zhao, M. Ghaffari, L. Liao, and D. Siegel, “Prognostics and health management design for rotary machinery systems—Reviews, methodology and applications,” *Mechanical Systems and Signal Processing*, vol. 42, no. 1–2, pp. 314–334, 2014.
- [8] A. K. S. Jardine, D. Lin, and D. Banjevic, “A review on machinery diagnostics and prognostics implementing condition-based maintenance,” *Mechanical Systems and Signal Processing*, vol. 20, no. 7, pp. 1483–1510, 2006.
- [9] *ISO 17359 :2018 — Condition monitoring and diagnostics of machines — General guidelines*, International Organization for Standardization Std., 2018.
- [10] Siemens (Senseye), “The true cost of downtime 2024,” Siemens AG, Tech. Rep., 2024, downtime costs : \$36,000-\$2.3M per hour by industry.
- [11] OECD, “The digital transformation of SMEs,” OECD Publishing, Tech. Rep., 2021.
- [12] *ISO 20816-1 :2016 — Mechanical vibration — Measurement and evaluation of machine vibration — Part 1 : General guidelines*, International Organization for Standardization Std., 2016.
- [13] I. U. Hassan, K. Panduru, and J. Walsh, “An in-depth study of vibration sensors for condition monitoring,” *Sensors*, vol. 24, no. 3, p. 740, 2024.

- [14] M. Tiboni, C. Remino, R. Bussola, and C. Amici, “A review on vibration-based condition monitoring of rotating machinery,” *Applied Sciences*, vol. 12, no. 3, p. 972, 2022.
- [15] *ISO 20816-3 :2022 — Mechanical vibration — Measurement and evaluation of machine vibration — Part 3 : Industrial machinery with power rating above 15 kW*, International Organization for Standardization Std., 2022.
- [16] S. Arciniegas, D. Rivero, J. Piñan, E. Diaz, and F. Rivas, “IoT device for detecting abnormal vibrations in motors using TinyML,” *Discover Internet of Things*, vol. 5, p. 41, 2025.
- [17] I. Bagri, K. Tahiry, A. Hraiba, A. Touil, and A. Mousrij, “Vibration signal analysis for intelligent rotating machinery diagnosis and prognosis : A comprehensive systematic literature review,” *Vibration*, vol. 7, no. 4, pp. 1013–1062, 2024.
- [18] J. W. Cooley and J. W. Tukey, “An algorithm for the machine calculation of complex Fourier series,” *Mathematics of Computation*, vol. 19, no. 90, pp. 297–301, 1965.
- [19] V. Chandola, A. Banerjee, and V. Kumar, “Anomaly detection : A survey,” *ACM Computing Surveys*, vol. 41, no. 3, pp. 15 :1–15 :58, 2009.
- [20] J. B. MacQueen, “Some methods for classification and analysis of multivariate observations,” in *Proceedings of the 5th Berkeley Symposium on Mathematical Statistics and Probability*, vol. 1. Berkeley, CA, USA : University of California Press, 1967, pp. 281–297.
- [21] D. Arthur and S. Vassilvitskii, “k-means++ : The advantages of careful seeding,” in *Proceedings of the 18th Annual ACM-SIAM Symposium on Discrete Algorithms*. SIAM, 2007, pp. 1027–1035,  $O(\log k)$  approximation, 2-3x faster convergence.
- [22] M. Antonini, M. Pincheira, M. Vecchio, and F. Antonelli, “An adaptable and unsupervised TinyML anomaly detection system for extreme industrial environments,” *Sensors*, vol. 23, no. 4, p. 2344, 2023, isolation Forest on ESP32\_WROVER\_IE (4 MB SPIRAM), <16ms latency, 84KB RAM usage.
- [23] M. Jemmali, “Maintenance prédictive pour une turbine de puissance en utilisant des algorithmes d’apprentissage machine,” Master’s thesis, École de technologie supérieure, Montréal, Canada, 2021, french regional reference, ML comparisons for rotating machinery.
- [24] T. Langer, M. Widra, and V. Beyer, “TinyML towards Industry 4.0 : Resource-efficient process monitoring of a milling machine,” Aug. 2025, arXiv preprint.
- [25] S. Gupta and S. N. Shivhare, “Embedded TinyML for predictive maintenance : Vibration analysis on ESP32 with real-time fault detection in industrial equipment,” *International Journal of Computing, Mathematics and Applications*, vol. 2, no. 2, 2025, eSP32+ADXL345 implementation, >92% accuracy - exact hardware match.
- [26] C. Banbury, V. J. Reddi, P. Torelli, J. Holleman, N. Jeffries, C. Kiraly, P. Montino, D. Kanter, S. Ahmed, D. Pau *et al.*, “MLPerf Tiny benchmark,” in *Proceedings of the Neural Information Processing Systems Track on Datasets and Benchmarks*, vol. 1, 2021, also available at arXiv :2106.07597.